

alumnos que estudiaron una lengua extranjera durante al menos dos años es mucho más alta que la de los alumnos que no la estudiaron. El director de la escuela argumenta que estos datos no constituyen una buena evidencia de que el estudio de lenguas extranjeras aumente el dominio de la lengua propia. Identifica las variables explicativa y respuesta de este estudio. Luego, explica qué variable latente anula la conclusión de que el estudio de lenguas mejora el dominio de la lengua propia.

**2.66. Formación e ingresos.** Existe una fuerte correlación positiva entre los años de escolarización  $x$  y los ingresos a lo largo de la vida  $y$  de los hombres en Europa. Una posible razón de esta asociación es causal: más educación conduce a empleos mejor pagados. De todas formas, variables latentes podrían explicar una parte de la correlación. Sugiere algunas variables latentes que explicarían por qué los hombres con más formación ganan más.

**2.67. Las líneas de alta tensión, ¿provocan cáncer?** Se ha sugerido que los campos electromagnéticos como los que se hallan junto a las líneas de alta tensión pueden causar leucemia en los niños. Estudios minuciosos sobre el tema no han hallado ninguna asociación entre la exposición a campos electromagnéticos y la leucemia infantil.<sup>30</sup>

Sugiere algunas variables latentes sobre las que quisieras información con el objetivo de investigar la afirmación de que vivir junto a una línea de alta tensión está asociado con el cáncer.

## 2.6 Relaciones entre variables categóricas \*

Hasta ahora, nos hemos concentrado en relaciones en las que al menos la variable respuesta era cuantitativa. Ahora nos interesaremos en relaciones entre dos o más variables categóricas. Algunas variables —como son el sexo, la raza o la profesión— son intrínsecamente categóricas. Otras variables categóricas se crean agrupando valores de variables cuantitativas en clases. Cuando se publican datos, a menudo se presentan en forma agrupada para ahorrar espacio. Para analizar datos categóricos utilizamos recuentos o porcentajes de los individuos que componen las distintas clases o categorías.

<sup>30</sup>Gary Taubes, “Magnetic field-cancer link: will it rest in peace?”, *Science*, 277, 1997, pág. 29.

\*El contenido de este apartado es importante en estadística, pero en este libro no se necesita hasta el capítulo 8. Puedes omitirlo si no tienes pensado leer el capítulo 8, o retrasar su lectura hasta que no llegues a dicho capítulo.

EJEMPLO 2.19. Edad y educación

La tabla 2.10 presenta datos sobre el número de años de escolarización de ciudadanos estadounidenses de distintas edades. Muchos menores de 25 años todavía no han completado su educación, por lo que no se encuentran en la tabla. Las variables edad y educación se han agrupado en categorías. La tabla 2.10 es una **tabla de contingencia**, ya que describe dos variables categóricas. La educación es la **variable fila**, puesto que cada fila de la tabla describe a personas con un determinado nivel educativo. La edad es la **variable columna**, porque cada columna de la tabla describe a un grupo de edad distinto. Los valores de la tabla son los recuentos del número de personas que pertenecen a cada una de las categorías combinadas: edad y educación. Aunque las dos variables de la tabla son categóricas, las categorías de cada una de ellas se pueden ordenar de manera natural de menor a mayor. El orden de las columnas y de las filas de la tabla 2.10 refleja una ordenación natural de las distintas categorías. ■

Tablas de contingencia  
Variables fila y variables columna

Tabla 2.10. Años de escolarización según edad, datos de 1995 (en miles de personas).

| Educación                         | Grupo de edad |         |               | Total   |
|-----------------------------------|---------------|---------|---------------|---------|
|                                   | 25 a 34       | 35 a 54 | Mayores de 55 |         |
| No completaron secundaria         | 5.325         | 9.152   | 16.035        | 30.512  |
| Completaron secundaria            | 14.061        | 24.070  | 18.320        | 56.451  |
| De 1 a 3 cursos en la universidad | 11.659        | 19.926  | 9.662         | 41.247  |
| 4 o más cursos en la universidad  | 10.342        | 19.878  | 8.005         | 38.225  |
| Total                             | 41.388        | 73.028  | 52.022        | 166.438 |

2.6.1 Distribuciones marginales

¿Cómo podemos captar mejor la información contenida en la tabla 2.10? En primer lugar, *fíjate en la distribución de cada variable de forma separada*. La distribución de una variable categórica tan sólo dice con qué frecuencia ha ocurrido cada resultado. La columna “Total”, situada a la derecha de la tabla, contiene los totales de cada fila. Estos totales de las filas dan la distribución de la educación (la variable fila) entre toda la gente mayor de 25 años: 30.512.000 personas no completaron sus estudios de secundaria, 56.451.000 terminaron secundaria pero no fueron a la universidad, etc. De la misma manera, la fila “Total” en la parte inferior de la tabla da la distribución según la edad. Si la columna y la fila de totales no están,

lo primero que hay que hacer al analizar una tabla de contingencia es calcularlas. Las distribuciones de la variable fila y de la variable columna, de forma separada, se llaman **distribuciones marginales**, ya que aparecen en los márgenes derecho e inferior de la tabla de contingencia.

*Distribuciones marginales*

Si compruebas el cálculo de la fila y de la columna de totales de la tabla 2.10, encontrarás algunas discrepancias. Por ejemplo, la suma de los valores de la columna “25 a 34” es de 41.387 personas. El valor de la columna de totales para esta columna es de 41.388 personas. La explicación es el **error de redondeo**. Los valores de la tabla se expresan en miles de personas y cada valor se ha redondeado hasta el millar más próximo. Los técnicos que obtuvieron los totales lo hicieron a partir de los números exactos de personas entre 25 y 34 años, y posteriormente los redondearon. El resultado fue de 41.388.000 personas. Si se suman los valores ya redondeados que aparecen en la fila, se obtiene un valor ligeramente distinto.

*Error de redondeo*

A menudo, los porcentajes se captan más fácilmente que los recuentos. Podemos expresar la distribución marginal de la educación en forma de porcentajes dividiendo los valores de la columna de totales por el total de la tabla y multiplicando por cien.

#### *EJEMPLO 2.20. Cálculo de la distribución marginal*


El porcentaje de personas mayores de 25 años que completaron al menos 4 cursos universitarios es

$$\frac{\text{total con 4 años de universidad}}{\text{total}} = \frac{38,225}{166,438} = 0,230 = 23,0\%$$

Haremos tres cálculos más para obtener la distribución marginal de la educación en porcentajes. Aquí los tienes.

| Educación                         | Porcentaje |
|-----------------------------------|------------|
| No completaron secundaria         | 18,3       |
| Completaron secundaria            | 33,9       |
| De 1 a 3 cursos en la universidad | 24,8       |
| 4 o más cursos en la universidad  | 23,0       |

El total es el 100%, ya que cada individuo pertenece a uno de los cuatro grupos educativos. ■



**Figura 2.19.** Diagrama de barras de la distribución de la educación entre la gente con más de 25 años. Este diagrama corresponde a una de las distribuciones marginales de la tabla 2.10.

Cada distribución marginal de una tabla de contingencia es la distribución de una sola variable categórica. Tal como vimos en el capítulo 1, podemos utilizar un diagrama de barras o un diagrama de sectores para mostrar esta distribución. La figura 2.19 es un diagrama de barras sobre la distribución de la escolarización. Vemos que la gente con al menos algún año en la universidad constituye casi la mitad de la población con más de 25 años.

Cuando trabajas con tablas de contingencia, tendrás que calcular porcentajes, muchos porcentajes. He aquí una orientación para ayudar a decidir qué fracción da el porcentaje que quieres. Pregunta: “¿qué grupo representa el total sobre el que quiero el porcentaje?”. El recuento de este grupo es el denominador del cociente que permite obtener el porcentaje. En el ejemplo 2.20, queríamos el porcentaje “de gente mayor de 25 años”, por tanto, el recuento de gente mayor de 25 años (el total de la tabla) es el denominador.

## APLICA TUS CONOCIMIENTOS

**2.68.** Los recuentos de la columna “Total” situada a la derecha de la tabla 2.10 son recuentos de gente en cada grupo educativo. Explica por qué la suma de estos recuentos no es igual a 166.438, el total que aparece a la derecha de la última fila de la tabla.

**2.69.** A partir de los recuentos de la tabla 2.10, halla, en forma de porcentajes, la distribución marginal de la edad para la gente mayor de 25 años.

**2.70. Hábitos fumadores de padres e hijos.** Tenemos datos de ocho escuelas de secundaria sobre el consumo de tabaco entre los estudiantes y entre sus padres.<sup>31</sup>

| Hábitos de los padres          | Estudiantes fumadores | Estudiantes no fumadores |
|--------------------------------|-----------------------|--------------------------|
| Los dos padres fuman           | 400                   | 1.380                    |
| Sólo uno de los padres fuma    | 416                   | 1.823                    |
| Ninguno de los dos padres fuma | 188                   | 1.168                    |

(a) ¿A cuántos estudiantes describen estos datos?

(b) ¿Qué porcentaje de estos estudiantes son fumadores?

(c) Halla la distribución marginal del consumo de tabaco de los padres de dos maneras, con recuentos y en porcentajes.

### 2.6.2 Descripción de relaciones

La tabla 2.10 contiene, aparte de las dos distribuciones marginales de la edad y la educación, mucha más información. La naturaleza de la relación entre la edad y la educación no se puede deducir a partir de las distribuciones marginales; es necesaria toda la tabla. **Para describir las relaciones entre variables categóricas, calcula los porcentajes apropiados a partir de los recuentos.** Utilizamos porcentajes porque los recuentos suelen ser difíciles de comparar directamente. Por ejemplo, 19.878.000 personas entre 35 y 54 años completaron sus estudios universitarios, mientras que sólo 8.005.000 personas con al menos 55 los completaron.

<sup>31</sup>S. V. Zagona (ed.), *Studies and Issues in Smoking Behavior*, University of Arizona Press, Tucson, 1967, págs. 157-180.

El grupo más joven es mucho mayor; por tanto, no podemos comparar directamente estos recuentos.

*EJEMPLO 2.21. Educación universitaria*

¿Qué porcentaje de personas entre 25 y 34 años completaron 4 cursos de estudios universitarios? Se trata del recuento de personas entre 25 y 34 años que completaron 4 cursos universitarios expresado como porcentaje del total de personas de este grupo de edad:

$$\frac{10,342}{41,388} = 0,250 = 25,0\%$$

“Las personas entre 25 y 34” es el grupo del cual queremos un porcentaje; por tanto, el recuento de este grupo es el denominador. De la misma manera, halla el porcentaje de gente de cada grupo de edad con al menos 4 cursos en la universidad. La comparación de los tres grupos es

| Grupos de edad | Porcentaje de alumnos<br>con al menos 4 cursos universitarios |
|----------------|---------------------------------------------------------------|
| 25-34          | 25,0                                                          |
| 35-54          | 27,2                                                          |
| 55 o más       | 15,4                                                          |

Estos porcentajes nos ayudan a ver cómo la educación universitaria es menos frecuente entre los estadounidenses de 55 o más años que entre adultos más jóvenes. Éste es una aspecto importante de la asociación entre edad y educación. ■

**APLICA TUS CONOCIMIENTOS**

**2.71.** Utilizando los recuentos de la tabla 2.10, halla el porcentaje de gente de cada grupo de edad que no terminó la secundaria. Dibuja un diagrama de barras para comparar estos porcentajes. Explica lo que muestran los datos.

**2.72. Huevos de serpientes de agua.** ¿Cómo influye la temperatura sobre la eclosión de los huevos de serpiente de agua? Unos investigadores distribuyeron huevos recién puestos a tres temperaturas: caliente, templada y fría. La temperatura del agua caliente era el doble de la temperatura de la hembra de serpiente de

agua y la temperatura del agua fría era la mitad de la temperatura corporal de la hembra de serpiente de agua. He aquí los datos sobre el número de huevos y el número de huevos que eclosionaron.<sup>32</sup>

|                     | Fría | Templada | Caliente |
|---------------------|------|----------|----------|
| Número de huevos    | 27   | 56       | 104      |
| Huevos eclosionados | 16   | 38       | 75       |

(a) Construye una tabla de contingencia con la temperatura y el resultado de la eclosión (sí o no).

(b) Calcula el porcentaje de huevos de cada grupo que eclosionó. Los investigadores opinaban que los huevos no eclosionarían en agua fría. Los datos, ¿apoyan esta opinión?

### 2.6.3 Distribuciones condicionales

El ejemplo 2.21 no compara las distribuciones de la educación de los tres grupos de edad. Sólo compara los porcentajes de la gente con al menos 4 cursos universitarios. Vamos a ver la situación completa.

#### EJEMPLO 2.22. Cálculo de distribuciones condicionales

La información sobre el grupo de edad entre 25 y 34 años aparece en la primera columna de la tabla 2.10. Para hallar la distribución completa de la educación en este grupo, mira sólo esta columna. Transforma cada recuento en un porcentaje en relación con el total de la columna, 41.338. He aquí la distribución:

|            | No terminaron<br>secundaria | Terminaron<br>secundaria | De 1 a 3 cursos<br>universitarios | 4 o más cursos<br>universitarios |
|------------|-----------------------------|--------------------------|-----------------------------------|----------------------------------|
| Porcentaje | 12,9                        | 34,0                     | 28,2                              | 25,0                             |

La suma de estos porcentajes tiene que ser 100, ya que todos los individuos de 25 a 34 años pertenecen a alguna de las categorías educativas (de hecho, la suma

<sup>32</sup>R. Shine, T. R. L. Madsen, M. J. Elphick y P. S. Harlow, "The influence of nest temperatures and maternal brooding on hatchling phenotypes in water pythons", *Ecology*, 78, 1997, págs. 1.713-1.721.

Distribución  
condicional

es 100,1 debido al error de redondeo). Estos cuatro porcentajes son la **distribución condicional** de la educación dado que una persona tiene entre 25 y 34 años. Utilizamos el término “condicional” porque la distribución se refiere sólo a las personas que satisfacen la condición de tener entre 25 y 34 años. ■


Ahora fíjate en la segunda (gente de 35 a 54 años) y en la tercera columna (gente de 55 o más años) de la tabla 2.10 para hallar dos distribuciones condicionales más. Los programas estadísticos pueden expresar rápidamente los valores de cada columna como porcentajes en relación con el total de la columna. La figura 2.20 muestra este resultado. El programa halló los totales de filas y columnas a partir de los valores de la tabla; pueden ser distintos de los de la tabla 2.10.

Cada celda de esta tabla contiene el recuento de la tabla 2.10, así como este recuento expresado como un porcentaje del total de la columna. Los porcentajes de cada columna constituyen la distribución condicional de los años de escolarización de cada grupo de edad. Los porcentajes de cada columna suman 100%, ya que se tiene en cuenta a toda la gente de cada grupo de edad. La comparación de las distribuciones condicionales pone de manifiesto el tipo de asociación existente entre edad y educación. La distribución de la educación en los dos grupos más jóvenes es bastante similar; sin embargo, la educación superior es menos común en el grupo de gente de 55 o más años.

| TABLA DE EDUCACION POR EDAD |       |       |         |        |
|-----------------------------|-------|-------|---------|--------|
| EDUCACION                   | EDAD  |       |         |        |
| Frequency                   |       |       |         |        |
| Col Pct                     | 25-34 | 35-54 | 55 over | Total  |
| NoSecund                    | 5325  | 9152  | 16035   | 30512  |
|                             | 12.87 | 12.53 | 30.82   |        |
| SoloSecund                  | 14061 | 24070 | 18320   | 56451  |
|                             | 33.97 | 32.96 | 35.22   |        |
| Univ_1_3                    | 11659 | 19926 | 9662    | 41247  |
|                             | 28.17 | 27.29 | 18.57   |        |
| Univ_sup4                   | 10342 | 19878 | 8005    | 38225  |
|                             | 24.99 | 27.22 | 15.39   |        |
| Total                       | 41387 | 73026 | 52022   | 166435 |

**Figura 2.20.** Resultados del SAS de la tabla de contingencia de edad por educación, con las distribuciones condicionales de la educación en cada grupo de edad. Los porcentajes de cada columna suman 100%.





**Figura 2.21.** Diagrama de barras para comparar los niveles educativos de tres grupos de edad. Dentro de cada nivel educativo, cada barra compara los porcentajes de tres grupos de edad.

Los diagramas de barras pueden ayudar a visualizar una asociación. Dibujaremos tres diagramas de barras en un mismo gráfico, cada uno de ellos similar al de la figura 2.19, para mostrar las tres distribuciones condicionadas. La figura 2.21 muestra una forma alternativa de diagrama de barras. Cada conjunto de tres barras compara los porcentajes en cada uno de los grupos de edad que ha alcanzado un determinado nivel educativo. Es fácil ver que las barras de “25 a 34”

y de “35 a 54” son similares en los cuatro niveles de educación, y que las barras de “55 o más años” muestran que mucha más gente de este grupo no terminó secundaria y que muy pocos llegaron a la universidad.

No existe ningún gráfico (como por ejemplo los diagramas de dispersión) que visualice la forma de la relación entre variables categóricas. Tampoco existe ningún resumen numérico (como por ejemplo la correlación) que valore la fuerza de la asociación. Los diagramas de barras son lo suficientemente flexibles como para visualizar las comparaciones que quieras mostrar. Como resúmenes numéricos utilizaremos los porcentajes adecuados. Debes decidir qué porcentajes necesitas. He aquí una sugerencia: compara las distribuciones condicionales de la variable respuesta (educación) correspondientes a cada uno de los valores de la variable explicativa (edad). Es lo que hicimos en la figura 2.20.

### APLICA TUS CONOCIMIENTOS

**2.73.** Halla la distribución condicional de la edad entre la gente con al menos 4 cursos universitarios. Parte de los recuentos de la tabla 2.10. (Para hacerlo, fíjate sólo en la fila de “4 o más cursos en la universidad” de la tabla.)

**2.74. Planes profesionales de hombres y mujeres.** Un estudio sobre los planes profesionales de mujeres y hombres jóvenes envió cuestionarios a los 722 alumnos de una clase de último curso de Administración de Empresas de la University of Illinois. Una de las preguntas formuladas era qué especialidad habían escogido. He aquí datos sobre lo que contestaron los alumnos.<sup>33</sup>

|                | Mujeres | Hombres |
|----------------|---------|---------|
| Contabilidad   | 68      | 56      |
| Administración | 91      | 40      |
| Economía       | 5       | 6       |
| Finanzas       | 61      | 59      |

(a) Halla la distribución de la especialidad condicionada al sexo de los estudiantes. A partir de tus resultados describe las diferencias entre hombres y mujer con un gráfico y con palabras.

<sup>33</sup>F. D. Blau y M. A. Ferber, “Career plans and expectations of young women and men”, *Journal of Human Resources*, 26, 1991, págs. 581-607.

(b) ¿Qué porcentaje de estudiantes no respondió el cuestionario? La falta de respuesta debilita los resultados obtenidos.

2.75. He aquí los totales de filas y columnas de una tabla de contingencia con dos filas y dos columnas.

|     |     |     |
|-----|-----|-----|
| $a$ | $b$ | 50  |
| $c$ | $d$ | 50  |
| 60  | 40  | 100 |

Halla *dos diferentes* conjuntos de recuentos  $a$ ,  $b$ ,  $c$  y  $d$  que den los mismos totales. Este ejercicio muestra que la relación entre dos variables no se puede obtener a partir de las distribuciones individuales de las variables.

#### 2.6.4 Paradoja de Simpson

Tal como ocurre con las variables cuantitativas, los efectos de las variables latentes pueden cambiar e incluso invertir las relaciones observadas entre dos variables categóricas. He aquí un ejemplo hipotético que muestra las sorpresas que pueden aguardar a quien utiliza, confiado, datos estadísticos.

EJEMPLO 2.23. *¿Qué hospital es más seguro?*

Para ayudar a los ciudadanos a tomar decisiones sobre el cuidado de su salud, en Estados Unidos se publican datos sobre los hospitales del país. Imagínate que quieres comparar el Hospital A con el Hospital B de una misma ciudad. He aquí una tabla de contingencia con los datos sobre la supervivencia de los enfermos después de ser operados en estos dos hospitales. Todos los pacientes que han sido operados últimamente están incluidos. “Sobrevivió” significa que el paciente vivió al menos durante las 6 semanas siguientes a la operación.

|                  | Hospital A | Hospital B |
|------------------|------------|------------|
| No sobrevivieron | 63         | 16         |
| Sobrevivieron    | 2.037      | 784        |
| Total            | 2.100      | 800        |