

Descripción de Variables Categorías

Unidad 4: Estadística Descriptiva Univariada

Gabriel Sotomayor

2025-10-13

Objetivos de la Sesión de Hoy

- Revisar la distinción entre variables categóricas y cuantitativas.
- **Calcular e interpretar** tablas de frecuencias absolutas, relativas y porcentajes.
- **Identificar** la **moda** como la medida de tendencia central apropiada para datos categóricos.
- **Comprender** el concepto y la utilidad de las **tasas** en el análisis sociológico.
- **Crear e interpretar** gráficos de barras, discutiendo buenas prácticas de visualización.



1. El Primer Paso del Análisis: Describir

Repaso y Conexión

En la Unidad 3, aprendimos a **preparar y manipular** nuestras bases de datos en R. Ahora que tenemos los datos limpios y ordenados, comenzamos a **analizarlos**.

El primer paso de cualquier análisis de datos es la **estadística descriptiva univariada**: las herramientas que nos permitan resumir y describir cada variable por sí sola.



La Distinción Fundamental

Las herramientas que usamos para describir una variable dependen fundamentalmente de su tipo. Recordemos la distinción clave:

Variables Categóricas

- **Definición:** Indican a qué grupo o categoría pertenece una observación.
- **Niveles de Medición:** Nominal, Ordinal.
- **Ejemplos:** `sexo`, `region`, `nivel_educacional`.
- **Análisis:** Se basa en **conteos** de casos por categoría.

Variables Cuantitativas (o Numéricas)

- **Definición:** Toman valores numéricos sobre los cuales las operaciones aritméticas tienen sentido.
- **Niveles de Medición:** Intervalo, Razón.
- **Ejemplos:** `edad`, `ingreso`, `años_escolaridad`.
- **Análisis:** Se basa en la descripción de la **distribución** de los valores.

Hoy, nos enfocaremos exclusivamente en las variables categóricas.



2. Resúmenes Numéricos para Variables Categóricas

Tablas de Frecuencia: La Herramienta Central

La forma más básica y fundamental de describir una variable categórica es a través de una **tabla de frecuencias**. Esta tabla nos muestra la **distribución** de la variable: qué valores toma y con qué frecuencia.

- **Frecuencia Absoluta (n)**: Es el **conteo simple** del número de casos u observaciones en cada categoría.

Ejemplo: Distribución de la variable **sexo** en una muestra de 10 personas.

Categoría (Sexo)	Frecuencia Absoluta (n)
Hombre	4
Mujer	6
Total	10

Nos dice *cuántos* hay en cada grupo, pero es difícil de comparar si los totales son diferentes.



De Conteos a Comparaciones: Frecuencias Relativas

Para comparar la distribución de una variable entre grupos de diferentes tamaños, necesitamos estandarizar los conteos. Para esto usamos las **frecuencias relativas**.

- **Proporción:** Es la frecuencia de una categoría dividida por el número total de casos. El valor va de 0 a 1.
 - *Fórmula:* $\text{Proporción} = n_{\text{categoria}} / n_{\text{total}}$
- **Porcentaje:** Es la proporción multiplicada por 100. Es más fácil de interpretar y comunicar.
 - *Fórmula:* $\text{Porcentaje} = (n_{\text{categoria}} / n_{\text{total}}) * 100$

Categoría (Sexo)	Frecuencia (n)	Proporción	Porcentaje (%)
Hombre	4	0.4	40%
Mujer	6	0.6	60%
Total	10	1.0	100%

Ahora podemos decir que “el 60% de la muestra son mujeres”, una afirmación comparable con otras encuestas.



La Moda: El Centro de las Categorías

Para las variables categóricas, la única medida de tendencia central que podemos calcular es la **moda**.

- **Definición:** La **moda** es la categoría que tiene la **mayor frecuencia** en una distribución.
- Es la categoría “más típica” o “más común”.

Ejemplo: Afiliación religiosa en una muestra.

Religión	Frecuencia
Católica	450
Evangélica	300
Ninguna	250

La moda es “Católica”, ya que es la categoría con el mayor número de casos (450).

Importante: La moda es la **categoría** (“Católica”), no el número de casos (450).



Ejemplo Aplicado: La Fuerza de Trabajo en Chile

Para aplicar estos conceptos, usaremos datos reales de la **Encuesta Nacional de Empleo (ENE)** del INE. Esta encuesta mide periódicamente el estado del mercado laboral en Chile y es fundamental para el diagnóstico y la creación de políticas públicas.

Nos centraremos en la variable **condición de actividad** (**activ**) para la población de 15 años y más. Esta variable categórica clasifica a las personas en tres grupos mutuamente excluyentes, que definen su relación con el trabajo remunerado:

- **Ocupados:** Personas que trabajaron al menos una hora de forma remunerada durante la semana de referencia, o que, teniendo un empleo, no trabajaron temporalmente por razones específicas (vacaciones, enfermedad, etc.).
- **Desocupados:** Personas que no estaban ocupadas, pero que estaban disponibles para trabajar y habían realizado una búsqueda activa de empleo recientemente (cesantes y quienes buscan trabajo por primera vez).
- **Inactivos o Fuera de la Fuerza de Trabajo:** Personas que no estaban ocupadas ni buscaron activamente trabajo (ej. estudiantes, jubilados, personas dedicadas al trabajo doméstico no remunerado).



Tabla de Frecuencias: Condición de Actividad

El primer paso es construir una tabla de frecuencias para describir la distribución de esta variable. Usaremos los datos de la ENE para el trimestre móvil Junio-Julio-Agosto de 2024.

Tabla 1: Distribución de la Condición de Actividad (Población 15 años y más)

condicion_actividad	Frecuencia Absoluta (n)	Proporcion	Porcentaje
Ocupado	53209	0.532	53.2
Desocupado	5011	0.050	5.0
Fuera de la fuerza de trabajo	41780	0.418	41.8



Tasas: Una Medida Estandarizada para la Comparación

Una **tasa** es un tipo especial de frecuencia relativa que se usa para comparar la ocurrencia de un evento entre poblaciones de diferentes tamaños.

- **Definición:** Relaciona el número de eventos de interés con el total de la población “en riesgo” de experimentar ese evento, multiplicado por una constante (generalmente 1.000, 10.000 o 100.000).
- **Fórmula:** $Tasa = (N^{\circ} \text{ de eventos} / \text{Población total en riesgo}) * k$
- **Uso Común:** Tasas de natalidad, mortalidad, desempleo, homicidios, etc.



Tasas: Una Medida Estandarizada para la Comparación

Ejemplo: Tasa de homicidios.

- **Comuna A:** 10 homicidios en una población de 50.000.
- **Comuna B:** 20 homicidios en una población de 500.000.

¿Dónde es más “violento”?

- **Tasa A:** $(10 / 50.000) * 100.000 = 20$ homicidios por cada 100.000 habitantes.
- **Tasa B:** $(20 / 500.000) * 100.000 = 4$ homicidios por cada 100.000 habitantes.

Conclusión: Aunque la Comuna B tuvo más homicidios en términos absolutos, la Comuna A tiene una tasa de homicidios 5 veces mayor. Las tasas nos permiten hacer comparaciones justas.




Tasas en Acción: Analizando la Crisis de Natalidad en Chile

Para ilustrar el poder de las tasas en el análisis sociológico, examinaremos uno de los cambios demográficos más profundos del Chile contemporáneo: la drástica caída de la natalidad. Para ello, usaremos dos indicadores clave.



La Caída de la Fecundidad en Chile (1992-2024)

El siguiente gráfico visualiza la evolución de ambos indicadores. La línea roja punteada marca la tasa de reemplazo poblacional de 2,1 hijos por mujer.



Fuente: Elaboración propia con datos de estadísticas vitales del INE.



Contexto Sociológico: ¿Por qué hay menos nacimientos?

La socióloga Martina Yopo, experta en género y reproducción, ofrece un diagnóstico complejo que va más allá de las decisiones individuales.

“Mucha gente piensa que no hay futuro para hacer familia en Chile” — Martina Yopo

Algunas claves del fenómeno:

- **Infertilidades Estructurales:** No se trata solo de que las personas “no quieran” tener hijos, sino de la “falta de condiciones sociales para tener y criar hijos”.
- **Tensiones Estructurales:** Existe un conflicto entre el mundo del trabajo y la vida familiar, que recae desproporcionadamente sobre las mujeres. La maternidad a menudo obstaculiza el desarrollo laboral y personal.
- **Futuro Incierto:** La crisis climática, la inestabilidad política y la precariedad económica generan una “desesperanza estructural” que desincentiva la formación de familias.



3. Visualización de Variables Categóricas

Gráfico de Barras: La Herramienta Estándar


Las tablas de frecuencia son precisas, pero no siempre son la forma más rápida de comunicar un patrón. Nuestro cerebro procesa la información visual de manera mucho más eficiente.

El **gráfico de barras** es la forma más clara y efectiva de visualizar la distribución de una variable categórica.

- Cada barra representa una categoría.
- La **altura** de la barra representa la frecuencia (absoluta o porcentual) de esa categoría.



Gráfico de Barras: Nuestro Primer Vistazo Visual



Este gráfico es un buen primer paso. Nos permite ver de un vistazo que la categoría “Ocupado” es la moda. Sin embargo, el orden de las categorías es alfabético, lo que no es ideal para la comparación, y las frecuencias absolutas son difíciles de interpretar sin el total.



Buenas Prácticas: Hacia un Gráfico Informativo

Para que un gráfico de barras sea una herramienta de análisis poderosa y honesta, debe seguir algunas reglas:

1. **Usar Porcentajes:** Son más fáciles de interpretar y comparar que las frecuencias absolutas.
2. **Ordenar las Barras:** Ordenar las barras de mayor a menor (o viceversa) facilita la comparación visual y destaca la jerarquía.
3. **Etiquetar Directamente:** Añadir los valores (porcentajes) directamente sobre las barras reduce la carga cognitiva del lector.
4. **Título y Subtítulo Informativos:** El título debe comunicar el hallazgo principal, no solo describir el gráfico.
5. **Eje Y en Cero:** Empezar el eje Y en un valor mayor a cero es una práctica engañosa que distorsiona las proporciones.




Aplicando Buenas Prácticas al Gráfico de la ENE

Ahora, apliquemos todas estas reglas para crear un gráfico final de calidad de publicación.

Más de la mitad de la población mayor de 15 años está ocupada

Distribución de la Condición de Actividad, Trimestre JJA 2024




Fuente: Elaboración propia a partir de Encuesta Nacional de Empleo (ENE).



¿Y por qué no un Gráfico de Torta?

Aunque son muy populares, los gráficos de torta son desaconsejados por la mayoría de los expertos en visualización de datos.



¿Y por qué no un Gráfico de Torta?

El Problema: Nuestro cerebro es muy malo para comparar **ángulos** y **áreas**, pero es muy bueno para comparar **longitudes** en una escala común (como las alturas de las barras).

Pregunta: En el gráfico de torta, ¿es fácil ver qué tan grande es la categoría “Desocupado” en comparación con “Fuera de la fuerza de trabajo”? En el gráfico de barras, la comparación es instantánea.

Regla General: Usa un gráfico de barras para comparar categorías. Reserva los gráficos de torta solo si tienes 2 o 3 categorías y quieres enfatizar la composición de un todo.



Cierre y Próximos Pasos

Resumen de la sesión de hoy:

- Hemos aprendido que la descripción de **variables categóricas** se basa en el **conteo**.
- Las **tablas de frecuencia** (absolutas y relativas) y la **moda** son nuestras herramientas numéricas fundamentales.
- Las **tasas** nos permiten hacer comparaciones justas entre grupos de diferentes tamaños.
- El **gráfico de barras** es la herramienta visual estándar y más efectiva para este tipo de variables.

En el práctico de hoy:

- Aplicarán estas técnicas en R. Usarán `dplyr::count()` para crear tablas de frecuencia y `ggplot2::geom_bar()` para crear sus primeros gráficos de barras, poniendo en práctica las buenas prácticas de visualización.

Adelanto de la próxima clase:

- Nos adentraremos en el mundo de las **variables cuantitativas**, aprendiendo a describir su forma, centro y dispersión con herramientas como el **histograma** y el **boxplot**.

