

Visualizando Distribuciones y Medidas Robustas

Unidad 4: Estadística Descriptiva Univariada

Gabriel Sotomayor

2025-10-20



Objetivos de la Sesión de Hoy

- Introducir el marco para describir una variable cuantitativa: **Forma, Centro y Dispersión**.
- Aprender a visualizar la **forma** de una distribución usando **Histogramas**.
- Calcular e interpretar las medidas de **centro y dispersión robustas**: **Mediana, Cuartiles y Rango Intercuartil (IQR)**.
- Construir e interpretar el **Resumen de Cinco Números** y su visualización: el **Boxplot**.



1. Descripción de Variables Cuantitativas

De las Categorías a los Números

En la clase anterior, aprendimos a describir variables categóricas contando casos y mostrando porcentajes (`table`, `count`, `geom_bar`).

Hoy, pasamos a las **variables cuantitativas** (de intervalo o razón), como la edad, los ingresos o los años de escolaridad.

Con estas variables, un simple conteo no es suficiente. Necesitamos herramientas para describir su **distribución**: cómo se reparten los valores a lo largo de un rango numérico.



El Mantra del Análisis Exploratorio de Datos (EDA)

Al enfrentarnos a una variable cuantitativa, nuestro objetivo es describir tres características fundamentales de su distribución:

1. **Forma:** ¿Cuál es el aspecto general de la distribución? ¿Es simétrica o asimétrica? ¿Tiene uno o varios picos (modas)?
2. **Centro:** ¿Alrededor de qué valor se agrupan los datos? ¿Cuál es el “caso típico”?
3. **Dispersión (o Variabilidad):** ¿Qué tan extendidos o concentrados están los datos?

Además, siempre debemos estar atentos a la presencia de **valores atípicos (outliers)**, que son observaciones que se desvían marcadamente del patrón general.



2. Visualizando la Forma: Histogramas

El Histograma: Un Retrato de la Distribución

El **histograma** es la principal herramienta gráfica para visualizar la forma de la distribución de una variable cuantitativa.


- **¿Cómo se construye?**
 1. El rango de la variable se divide en intervalos de igual ancho, llamados “bins” o “clases”.
 2. Se cuenta cuántas observaciones caen dentro de cada intervalo.
 3. Se dibuja una barra para cada intervalo, donde la altura de la barra es proporcional a la frecuencia.

A diferencia de un gráfico de barras, en un histograma el eje X es continuo y las barras van juntas.



Ingreso del Trabajo Principal en Chile

Para ilustrar estos conceptos, usaremos la **Encuesta Suplementaria de Ingresos (ESI) 2024** del INE. Nos centraremos en la variable `ing_t_p` (ingreso del trabajo principal) para los ocupados de referencia.



Fuente: Elaboración propia a partir de ESI 2024.



La Fuente de Datos: Encuesta Suplementaria de Ingresos (ESI)

- **¿Qué es?** La ESI es un módulo que se aplica anualmente (en el trimestre octubre-diciembre) a una submuestra de los hogares que participan en la **Encuesta Nacional de Empleo (ENE)**. Es la principal fuente de datos sobre ingresos en Chile.
- **Objetivo Principal:** Caracterizar en detalle los ingresos de las personas y los hogares, yendo mucho más allá de lo que la ENE puede capturar por sí sola. Mide:
 - Ingresos del trabajo principal y secundario.
 - Ingresos de fuentes no laborales (jubilaciones, arriendos, etc.).
 - Ingresos por trabajador/a por cuenta propia.
- **Relevancia Sociológica:** Los datos de la ESI son cruciales para analizar la **desigualdad económica**, la **brecha salarial de género** y la estructura del mercado laboral en Chile. Cuando leemos en las noticias sobre la “mediana del ingreso” en el país, esa cifra proviene de esta encuesta.



Interpretando la Forma: Asimetría (Sesgo)


La asimetría describe si la distribución está “cargada” o tiene una cola más larga hacia un lado.



Interpretando la Forma: Modalidad

La modalidad se refiere al número de picos o modas que tiene una distribución.

- **Unimodal:** La distribución tiene un solo pico principal. Es la forma más común, indicando que hay un valor o rango de valores claramente más frecuente que los demás.
- **Bimodal:** La distribución tiene dos picos distintos. A menudo es una señal importante de que nuestros datos provienen de **dos subgrupos diferentes** que no hemos separado.
 - *Ejemplo:* La distribución de estaturas en una muestra que mezcla hombres y mujeres probablemente será bimodal.
- **Multimodal:** Tiene varios picos.



3. Medidas de Centro y Dispersión Robustas

¿Qué es una Medida Robusta?

Una medida estadística es **robusta** si **no se ve afectada significativamente** por la presencia de valores extremos (outliers) o por la asimetría de la distribución.

Ejemplo:

- Datos: 1, 2, 3, 4, 100
- La presencia del 100 es un outlier.
- Una medida robusta del centro debería estar cerca de 3, ignorando la influencia desproporcionada del 100.

Hoy nos centraremos en las medidas robustas, que son ideales para describir distribuciones como la del ingreso.

La Mediana (M o Q2): El Centro Geométrico

La **mediana** es el valor que se encuentra en el punto medio exacto de los datos, una vez que han sido ordenados de menor a mayor.

- **Definición:** Es el **percentil 50**. Deja al 50% de las observaciones por debajo y al 50% por encima.
- **Propiedad Clave:** Es una medida de centro **robusta**. Su valor depende de la posición de los datos, no de su magnitud.

Ejemplo:

- Datos ordenados: 1, 2, ****3****, 4, 100 -> La mediana es 3.
- Datos ordenados: 1, 2, ****3****, 4, 10000 -> La mediana sigue siendo 3.

El outlier no afecta a la mediana. Por eso es la medida preferida para describir el “ingreso típico” en una población.



Cuartiles y Rango Intercuartil (IQR)

Así como la mediana divide los datos en dos mitades, los **cuartiles** los dividen en cuatro partes iguales.

- **Primer Cuartil (Q1):** Es el percentil 25. Deja al 25% de los datos por debajo.
- **Tercer Cuartil (Q3):** Es el percentil 75. Deja al 75% de los datos por debajo.

A partir de los cuartiles, construimos la principal medida de dispersión robusta:

- **Rango Intercuartil (IQR):** Es la distancia entre el tercer y el primer cuartil ($IQR = Q3 - Q1$).
- **Interpretación:** El IQR representa el **rango en el que se encuentra el 50% central de los datos**. Al igual que la mediana, es una medida de dispersión **robusta** porque ignora los valores en las colas de la distribución.



Percentiles: Más Allá de los Cuartiles

Los cuartiles son solo un tipo de **percentil** (o **cuantil**), un concepto más general y flexible para describir la posición de un valor dentro de una distribución ordenada.

- **Definición General:** El **percentil p** es el valor por debajo del cual se encuentra el $p\%$ de las observaciones.
 - La mediana es el percentil 50.
 - El primer cuartil (Q1) es el percentil 25.
 - El tercer cuartil (Q3) es el percentil 75.



Ejemplo: Los Quintiles de Ingreso

En sociología y políticas públicas, es muy común dividir a la población en **cinco grupos** de igual tamaño (20% cada uno). A estos grupos se les llama **quintiles**. Para definirlos, calculamos los percentiles 20, 40, 60 y 80.

Ejemplo con la ESI 2024:

Percentil	Ingreso Límite
P20	\$400.000
P40	\$548.629
P60	\$750.000
P80	\$1.200.000

- Una persona en el **primer quintil** gana hasta \$400.000.
- Una persona en el **quinto quintil** (el 20% más rico) gana más de \$1.200.000.

Podemos usar cualquier percentil para analizar la desigualdad. Por ejemplo, el **percentil 99** nos diría cuál es el ingreso del 1% más rico de la población.



El Resumen de Cinco Números y el Boxplot

El **resumen de cinco números** es el conjunto estándar de estadísticas robustas para describir una variable cuantitativa.

Componentes:

1. Mínimo
2. Primer Cuartil (Q1)
3. Mediana (M o Q2)
4. Tercer Cuartil (Q3)
5. Máximo

Este resumen se visualiza directamente a través de un **diagrama de caja y bigotes** o **boxplot**.



El Resumen de Cinco Números en la Práctica

Apliquemos estos conceptos a nuestra variable `ing_t_p` (ingreso del trabajo principal) de la ESI 2024. Este es el resumen numérico estándar para describir una distribución, especialmente si es asimétrica como la del ingreso.

Componentes: Mínimo, Primer Cuartil (Q1), Mediana, Tercer Cuartil (Q3) y Máximo.

Resumen de Cinco Números para el Ingreso
del Trabajo Principal (\$ CLP)

Medida	Ingreso Mensual
Mínimo	2.993
Q1 (Percentil 25)	461.456
Mediana (Percentil 50)	626.045
Q3 (Percentil 75)	1.009.749
Máximo	60.756.649




La Anatomía de un Boxplot

Un **diagrama de caja y bigotes** o **boxplot** es la visualización directa del resumen de cinco números y una de las herramientas más informativas de la estadística descriptiva.



- **La Caja:** Representa el **Rango Inter cuartil (IQR)**. Su longitud es una medida visual de la dispersión del 50% central de los datos.
- **La Línea Central:** Marca la **mediana** (Q2 o percentil 50).
- **Los Bigotes:** Se extienden hasta los valores mínimo y máximo “típicos” (generalmente 1.5 veces el IQR desde la caja).
- **Los Puntos:** Representan **valores atípicos (outliers)**, que son observaciones que caen más allá de los bigotes, permitiendo identificarlos fácilmente.




El Boxplot de Ingreso del Trabajo Principal

Apliquemos el boxplot a la variable de ingreso de la ESI 2024. Este gráfico nos permite ver de un solo vistazo la forma, el centro, la dispersión y la enorme cantidad de outliers.

Boxplot del Ingreso del Trabajo Principal en Chile

La compresión de la caja revela una fuerte asimetría y muchos outliers



Fuente: ESI 2024



La Escala Logarítmica

En el gráfico anterior, para poder visualizar la distribución del ingreso, aplicamos una transformación al eje: una **escala logarítmica**. Esta es una herramienta fundamental cuando trabajamos con variables que, como el ingreso, tienen una **fuerte asimetría positiva**.

- **El Problema de la Asimetría:** Cuando unos pocos valores muy altos (como los ingresos de las personas más ricas) son miles de veces más grandes que la mayoría, “aplastan” el resto del gráfico. La caja y los bigotes del boxplot, o un histograma, se comprimen tanto en la parte inferior que se vuelven casi invisibles, y perdemos toda la información sobre el 50% o 75% inferior de la población.

La Escala Logarítmica

¿Qué hace una Escala Logarítmica?

Una escala estándar (lineal) muestra los valores en sus unidades absolutas. La distancia entre 100.000 y 200.000 es la misma que entre 2.000.000 y 2.100.000.

Una escala logarítmica, en cambio, representa **órdenes de magnitud**. La distancia en el eje es la misma para cada **multiplicación** (usualmente $\times 10$). La distancia entre \$100.000 y \$1.000.000 ($\times 10$) es la misma que entre \$1.000.000 y \$10.000.000 ($\times 10$).

El Efecto Práctico:



Cierre y Próximos Pasos

Resumen de la sesión de hoy:

- Introdujimos el marco **Forma-Centro-Dispersión** para describir variables cuantitativas.
- Aprendimos a usar **histogramas** para visualizar la forma (asimetría, modalidad).
- Definimos y calculamos las **medidas robustas** de centro (**mediana**) y dispersión (**IQR**).
- Vimos cómo el **resumen de cinco números** se traduce en un **boxplot**, una poderosa herramienta visual.

En el práctico de hoy:

- Aplicarán estas técnicas en R para describir variables de la Encuesta CASEN, usando `geom_histogram`, `geom_boxplot`, `summary()` y `quantile()`.

Adelanto de la próxima clase:

- Exploraremos el otro par de medidas descriptivas: la **media** y la **desviación estándar**. Veremos por qué no son robustas y cuándo es apropiado usarlas.

