

Síntesis Bivariada y Medidas de Asociación

Unidad 5: Estadística Descriptiva Bivariada

Gabriel Sotomayor

2025-11-24

Objetivos de la Sesión de Hoy

- **Sintetizar** las estrategias visuales para cada tipo de análisis bivariado.
- **Introducir** el coeficiente de **Correlación de Pearson** (r) para cuantificar la fuerza y dirección de una relación lineal.
- **Desglosar** el concepto de **covarianza** como el paso previo a la correlación.
- **Discutir** las **limitaciones** de la correlación (outliers, no linealidad, causalidad).
- **Concluir** el curso conectando la estadística descriptiva con la **incertidumbre del muestreo** y el rol de la **probabilidad**.



1. El Mapa del Análisis Bivariado: Síntesis Visual

Eligiendo la Herramienta Correcta

Hemos explorado tres tipos de relaciones. A modo de resumen, este es nuestro mapa conceptual para elegir la visualización y el análisis numérico correctos:

Tipo de Relación	Pregunta Sociológica	Herramienta Visual (ggplot2)	Herramienta Numérica
Cat → Quant	¿Difieren los grupos?	<code>geom_boxplot</code> , <code>geom_density</code>	Tabla de medias/medianas por grupo
Cat → Cat	¿Se asocian las categorías?	<code>geom_bar(position="fill")</code>	Tabla de contingencia (% cond.)
Quant → Quant	¿Cómo covarían las variables?	<code>geom_point</code> (Scatterplot)	Correlación

Hoy, nos enfocaremos en profundidad en el último caso: la relación entre dos variables cuantitativas.



2. Del Gráfico de Dispersión a la Correlación

El Gráfico de Dispersión (Scatterplot)

El **gráfico de dispersión** es nuestra herramienta visual principal para analizar la relación entre dos variables cuantitativas. Nos permite evaluar tres aspectos clave:


1. **Dirección:** ¿La nube de puntos va hacia arriba o hacia abajo?
 - **Asociación Positiva:** A medida que X aumenta, Y tiende a aumentar.
 - **Asociación Negativa:** A medida que X aumenta, Y tiende a disminuir.
2. **Forma:** ¿El patrón sigue una línea recta (**lineal**) o una curva (**curvilíneo**)?
3. **Fuerza:** ¿Qué tan agrupados están los puntos alrededor del patrón principal? Puntos muy dispersos indican una relación débil; puntos muy juntos indican una relación fuerte.



Hacia una Medida Numérica: La Covarianza

Un gráfico de dispersión es subjetivo. Para cuantificar la relación, necesitamos un número. El primer paso es la **covarianza**.

La idea es dividir el gráfico en cuatro cuadrantes usando las medias de X e Y.



- **Asociación Positiva:** La mayoría de los puntos caen en los cuadrantes I y III.
- **Asociación Negativa:** La mayoría de los puntos caen en los cuadrantes II y IV.

La Covarianza (s_{xy})

La covarianza calcula el “promedio” del producto de las desviaciones de cada punto a sus respectivas medias.

$$Cov(x, y) = s_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

- Interpretación del signo:
 - Si $Cov(x, y) > 0$, la relación es positiva (puntos en cuadrantes I y III).
 - Si $Cov(x, y) < 0$, la relación es negativa (puntos en cuadrantes II y IV).
- Problema: La magnitud de la covarianza depende de las unidades de las variables (ej. pesos * años). ¡No es comparable! No nos dice si la relación es “fuerte” o “débil”.



La Solución: Correlación de Pearson (r)

Para resolver el problema de las unidades, **estandarizamos** la covarianza. La dividimos por el producto de las desviaciones estándar de cada variable. El resultado es el **coeficiente de correlación de Pearson (r)**.

$$r = \frac{Cov(x, y)}{s_x \cdot s_y} = \frac{1}{n - 1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right)$$

- ¡Clave! La fórmula de **r** es el promedio del producto de las **puntuaciones Z** de X e Y.
- **r** es un número **sin unidades**, que siempre va de **-1 a +1**, lo que lo hace universalmente comparable.




Interpretando la Correlación (r)

- **Rango:** Siempre entre -1 y +1.
- **Dirección:**
 - $r > 0$ indica una **asociación positiva**.
 - $r < 0$ indica una **asociación negativa**.
- **Fuerza:** La magnitud (el valor absoluto).
 - r cercano a 0: relación **lineal débil o nula**.
 - r cercano a -1 o +1: relación **lineal fuerte**.




Interpretando la Correlación (r)


$r \approx 0$




$r \approx 0.9$



$r \approx -0.5$



$r \approx -0.99$



3. Las Tres Advertencias sobre la Correlación


1. Correlación no implica Causalidad

Este es el mantra más importante de la estadística. Una correlación fuerte entre dos variables **nunca** es, por sí sola, evidencia suficiente para concluir que una causa la otra.

La relación podría ser una **asociación espuria**, causada por una tercera variable latente.



Asociación Positiva: Venta de Helados vs. Ahogamientos

Pero la causa común es la temperatura



2. La Correlación es Sensible a Outliers

Al igual que la media y la desviación estándar, la correlación es una medida **no robusta**. Un solo valor atípico puede distorsionar dramáticamente el coeficiente.




3. r Solo Mide Relaciones LINEALES

El coeficiente de correlación de Pearson está diseñado para medir qué tan bien se ajustan los datos a una **línea recta**. Si la relación es fuerte pero **curvilínea**, r puede ser engañosamente bajo.

Relación Curvilínea: Edad y Trabajo No Remunerado

Correlación lineal (r) ≈ 0.1



Conclusión: Un r cercano a 0 no significa “ausencia de relación”. Significa “ausencia de relación *lineal*”. Por eso, el análisis visual es irremplazable.

Cierre del Curso: Más Allá de la Descripción

Hemos pasado el curso aprendiendo a explorar, resumir y visualizar los patrones en **nuestros datos**.

Pero casi siempre, nuestros datos provienen de una **muestra**. Esto nos deja con la pregunta más importante de la estadística:

“En nuestra muestra de la ENUT, la brecha de género en trabajo doméstico es de 2.1 horas. ¿Es esta diferencia ‘real’ o podría ser una simple casualidad producto del azar del muestreo?”

Responder esta pregunta es el trabajo de la **Estadística Inferencial**.



- **El Problema:** La incertidumbre del muestreo.
- **La Herramienta:** La Teoría de la Probabilidad.
- **El Objetivo:** Hacer **inferencias** sobre la población a partir de la muestra y cuantificar nuestra confianza en esas conclusiones (p-valores, intervalos de confianza).

La estadística descriptiva que han aprendido es el fundamento indispensable para poder hacer inferencia de manera correcta. ¡Felicitaciones por completar este primer gran paso

